



中国大学生服务外包 创新创业大赛

China Students Service Outsourcing
Innovation and Entrepreneurship Competition

【A27】基于无人机实时航拍的目标智能检测与识别系统

组 名：_____ 天鹰智检 _____

指导老师：_____ 徐天阳 _____

组 长：_____

组 员：_____

目录

1.前言	4
1.1 项目背景	4
1.2 竞争分析	4
2.创意描述	5
2.1 模型创新：高精度与轻量化的协同突破	5
2.1.1 稀有类别感知重采样	6
2.1.2 架构层：P2 超高分辨率检测头与 CBAM 注意力增强	6
2.1.3 训练层：SFKR 重参数化卷积与 WIoU v3 损失函数	7
2.1.4 TPRD 语义拓扑蒸馏：让端侧模型具备大模型的语义判断力	7
2.2 多模态融合：填补夜间场景的感知盲区	8
2.2.1 M2D-LIF RGB-IR 双模态目标检测	8
2.3 系统创新：从检测工具到智能感知平台	9
2.3.1 自适应切片推理：高分辨率大图中的小目标不再漏检	9
2.3.2 天鹰 Agent：感知-决策-分析三层智能决策框架	9
3 总体技术实现	10
3.1 技术路线总览	10
3.2 整体模型架构	10
3.2.1 小目标检测模型架构（管线 A）	10
3.2.2 多模态检测模型架构（管线 B）	11
3.3 应用程序	11
3.3.1 整体构架图	11
3.3.2 运行流程	12
3.3.3 程序工具链	13
4.无人机视觉检测系统应用交互演示	15
4.1 用户登录界面	15
4.2 核心功能栏展示	15
4.2.1 实时检测模块	15
4.2.2 数据仪表盘模块	18
4.2.3 智能对话模块	19

4.2.4 多场景测试模块	20
4.3 工具栏展示	21
4.3.1 检测历史模块	21
4.3.2 数据导出模块	21
4.4 系统栏展示	22
4.4.1 系统设置模块	22
4.4.2 用户管理模块	24
4.4.3 我的账号模块	25
4.5 管理员报告后台	26
4.5.1 态势大屏	26
4.5.2 性能报告	27
4.5.3 检测历史	29
4.5.4 MLLM 案例库	30
4.5.6 系统监控	31
4.6 告警中心模块	31
5.性能测试	32
5.1 模型算法性能	32
5.1.2 VisDrone 消融实验链	32
5.1.3 DroneVehicle 多模态融合	33
5.1.4 TianYingLite 轻量化边缘模型	33
5.1.5 推理速度汇总	34
5.2 系统接口性能	35
6.开发环境与技术	35
7.应用环境	36
8.项目应用对象	36
8.1 桌面端应用对象	36
8.2 网页端应用对象	36
8.3 移动端应用对象	37
9. 项目总结	37
参考文献	38

1.前言

1.1 项目背景

随着全球无人机行业的高速扩张，2023 年全球智能航拍无人机市场销售额达到了 129.6 亿美元，预计 2030 年将达到 235 亿美元，而对无人机智能感知与目标识别能力提出更高要求的行业应用场景持续涌现，需求持续攀升。无人机航拍图像中的目标检测问题，是制约无人机行业从"工具化"向"智能化"跨越的核心瓶颈之一。

航拍图像中的目标检测任务面临高度复杂的挑战：飞行高度与角度的动态变化导致目标尺度差异极大；森林、城市楼群等复杂背景显著增加了前景目标的提取难度；光照不均、雨雾天气等环境因素使检测稳定性难以保障；此外，相机抖动与目标遮挡问题在实际飞行中也普遍存在，对算法的鲁棒性与泛化能力提出了远超常规的要求。



图 1 无人机实时航拍

传统无人机数据处理依赖人工目视判读，在现代无人机任务向高时效、大范围方向演进的背景下，人工判读已难以跟上数据产生的速度，无法满足实时响应的业务需求。长时间高强度目视作业还极易导致人员疲劳，造成漏检或误判，加剧任务失败风险。

面对行业对"实时感知、精准识别"的迫切需求，AI 目标检测技术为无人机行业提供了根本性的解决路径。深度学习目标检测模型能够精准捕捉小目标与密集目标，结合边缘计算框架实现端侧即时推理，显著缩短数据传输链路，赋能农业普查、应急救援、基础设施巡检等多个垂直行业的智能化升级，为无人机行业从"看得见"向"看得懂"的根本性转型提供核心技术支持。

1.2 竞争分析

当前，以 YOLO 系列、Faster R-CNN、RT-DETR 等算法为代表的深度学习模型已在无人机航拍目标检测领域得到探索和应用，并在标准数据集（如 VisDrone、DOTA 等）上展现了较好的基准性能。然而，在面向无人机实际部署场景时，现有方案仍面临若干关键挑战：

1. 边缘端算力适配困难：主流高精度检测模型参数量庞大，对高分辨率航拍视频流的实时推理需求极高。当模型部署于无人机载机或边缘计算单元时，难以在保持检测精度的同时满足实时处理要求，计算资源与性能指标之间的矛盾突出，成为算法工程化落地的首要障碍。
2. 小目标与密集目标检测能力不足：无人机飞行高度较高时，地面目标在图像中仅占数十像素，有效特征极为稀疏，极易被背景噪声淹没。现有通用检测模型对小目标的检测性能与正常尺度目标相比存在显著差距，难以满足航拍场景对小目标和密集群体目标的高召回需求。
3. 复杂环境泛化性弱：在实际无人机作业中，光照条件、天气状况、拍摄高度与角度均处于持续动态变化之中。现有模型对特定训练分布依赖性强，跨场景泛化能力不足，在域外环境下检测准确率波动显著，难以满足工业级应用对稳定性的要求。
4. 场景理解与智能分析能力不足：现有多数目标检测系统主要停留在“看得见”的阶段，即能够识别画面中“有什么目标”，却难以进一步理解“发生了什么、是否存在风险、应如何响应”。其输出通常仍以检测框、类别和置信度为主，缺乏对场景语义、行为异常、风险态势和任务决策的深层分析能力，难以满足无人机在安防巡检、交通治理、应急响应等实际场景中对“看得懂、会分析、能辅助决策”的更高要求。

综上所述，边缘端实时推理能力不足、小目标检测精度欠缺、复杂环境下鲁棒性不足，以及场景理解与智能分析能力薄弱，仍是当前无人机视觉智能系统亟待突破的核心技术难题。本项目旨在针对上述痛点，通过轻量化模型设计、多尺度特征增强、多模态智能分析与场景理解等技术路径，构建一套不仅“看得见”，更能够“看得懂”的高性能无人机目标检测与智能分析系统。

2. 创意描述

2.1 模型创新：高精度与轻量化的协同突破

针对无人机航拍场景中小目标密集、尺度变化剧烈、背景干扰强和端侧算力受限等问题，本项目围绕“输入图像如何经过多阶段表征、融合与优化，最终输出高质量检测结果”这一主线，构建了一套轻量高精度目标检测方法。

形式化地，给定输入图像

$$X = \mathbb{R}^{H \times W \times 3} \quad (1)$$

目标检测模型需要输出预测目标集合

$$\hat{Y} = \{(\hat{b}_i, \hat{c}_i, \hat{s}_i)\}_{i=1}^N \quad (2)$$

其中， $\hat{b}_i$ 为第 i 个目标的边界框坐标， $\hat{c}_i$ 为类别， $\hat{s}_i$ 表示置信度分数， N 为预测目标数量。

围绕该任务，本项目从数据层、架构层、训练层和蒸馏层四个方面进行改进：首先通过稀有类别感知重采样缓解长尾分布问题；随后在主干检测网络中引入 P2 检测头与 CBAM 注意力模块，增强超小目标表征；引入自研 SFKR (Spectral-guided Frequency-Kernel Reparameterization Conv) 重参数化卷积，扩展 P2 层等效感受野，强化超小目标细粒度特征提取；结合 WIoU v3 损失函数提升困难样本学习效率；在蒸馏

层，本项目探索了 TPRD 语义拓扑蒸馏框架，尝试将大模型语义知识迁移至端侧检测网络；实验验证了该思路在特定场景下的有效性，相关经验为后续模型迭代提供了参考。

2.1.1 稀有类别感知重采样

VisDrone 数据集具有明显长尾特征，行人与骑手两类目标占比较高，而 motor、van、bus 等类别样本数量明显不足。若直接采用随机采样，模型训练将长期受高频类别主导，不利于低频类别学习。

数据集类别分布分析与稀有类别感知重采样




图 2 数据集类别分布与稀有类别感知重采样

为此，本项目在 DataLoader 中引入稀有类别感知重采样机制。设第 k 类目标的标注频数为 f_k ，其稀有度分数定义为

$$r_k = \frac{1}{\sqrt{f_k}} \quad (3)$$

其中， r_k 越大表示该类别越稀有。

对于训练图像 X_j ，若其包含类别集合 $C(X_j)$ 则其采样权重定义为 w_j 训练时依据 w_j 进行加权随机采样，在总样本量不变的前提下提高低频类别样本被抽取的概率，从而缓解长尾偏差，为稀有类别提供更充分的训练机会。

2.1.2 架构层：P2 超高分辨率检测头与 CBAM 注意力增强

对于输入图像 X ，骨干网络首先提取多尺度特征

$$\{F_2, F_3, F_4, F_5\} \quad (4)$$

其中，F2 为浅层高分辨率特征，F5 为深层低分辨率特征。标准 YOLOv11-L 仅使用 P3/P4/P5 三尺度检测结构，其中最高分辨率检测层为 stride=8 的 P3，对 8px~32px 超小目标的感知能力有限。

为此，本项目在原有 FPN-PAN 架构基础上新增 stride=8 的 P2 检测头，使网络形成 P2/P3/P4/P5 四尺度检测结构。P2 分支通过上采样与浅层特征 Concat 融合，专门负责超小目标检测。

考虑到浅层特征语义较弱、背景噪声较强，本项目在 P2 分支后接入 CBAM 注意力模块。设输入特征为 F，则增强后的特征表示为

$$F' = M_s(F_C) \odot F_C, F_C = M_c(F) \odot F \quad (5)$$

其中， $M_c(\cdot)$ 和 $M_s(\cdot)$ 分别表示通道注意力与空间注意力映射， $\odot$ 表示逐元素乘法。该模块能够突出目标区域响应，抑制背景干扰，从而增强小目标表征能力。

2.1.3 训练层：SFKR 重参数化卷积与 WIoU v3 损失函数

标准 CIoU 对所有样本施加近似等权重，容易使大量简单样本主导训练过程，导致困难样本学习不足。为增强模型对困难样本的关注，本项目引入 WIoU v3 回归损失。

设预测框与真实框之间的交并比为 IoU，当前批次 IoU 的均值与标准差分别记为 μ_{IoU} 和 σ_{IoU} 定义样本偏移量

$$\beta = \frac{|IoU - \mu_{IoU}|}{\sigma_{IoU}} \quad (6)$$

其中， μ_{IoU} 和 σ_{IoU} 采用 detached 方式统计，不参与反向传播。

进一步定义加权系数

$$r = \exp(\text{clip}(\beta, \max = 4.0)) \quad (7)$$

其中， $\text{clip}(\cdot)$ 表示截断函数。最终 WIoU v3 损失为

$$L_{WIoU} = r \cdot (1 - IoU) \quad (8)$$

该损失通过动态调节梯度权重，使模型学习重心更多地集中到困难样本上。

为增强 P2 层超小目标细粒度特征的提取能力，本项目设计自研模块 SFKR (Spectral-guided Frequency-Kernel Reparameterization Conv)。训练时采用四路并行分支：7×7 DW+PW（大感受野主干）、3×3 Conv（局部边缘）、1×1 Conv（通道混合）、7×7 Spectral DW（拉普拉斯算子初始化，高通边缘响应）；推理时前三路通过结构重参数化折叠为单个 7×7 DW+PW，频谱旁路权重冻结，等效感受野从 3×3 扩展至 7×7，推理延迟仅增加约 3-8%。

2.1.4 TPRD 语义拓扑蒸馏：让端侧模型具备大模型的语义判断力

行人、骑手、摩托车等类别在视觉形态上较为相近，端侧检测模型在类间区分上存在一定困难。为增强其语义判别能力，本项目提出 TPRD（基于语义拓扑的原型表征蒸馏）框架，将大模型的类别语义知识迁移至检测特征空间。

设检测头输出的目标级特征为

$$Z_i = \mathbb{R}^d \quad (10)$$

对应类别的教师语义原型中心为

$$p_{c_i} = \mathbb{R}^{d'} \quad (11)$$

则蒸馏损失定义为

$$L_{TPRD} = 1 - \cos(g(z_{ij}), p_{c_i}) \quad (12)$$

其中, $g(\cdot)$ 表示投影映射函数, $\cos(\cdot, \cdot)$ 表示余弦相似度。

具体而言, 离线阶段使用 DINOv2-Large 对各类别目标图像块提取语义特征, 并计算类别原型中心; 在线阶段通过 RoIAlign 提取检测特征, 经投影 MLP 映射后与对应语义原型对齐。蒸馏完成后, 投影层可在推理时移除, 因此不会影响部署速度。该方法能够将大模型的语义判别能力注入端侧检测网络, 提升相近类别之间的区分能力。本项目对上述框架进行了完整实现与多组微调实验, 但在 VisDrone 验证集上未观察到稳定的精度增益, 分析认为主要受限于小目标 RoIAlign 特征信息量不足及预训练域差异, 相关实现已作为探索性成果保留。

2.2 多模态融合：填补夜间场景的感知盲区

2.2.1 M2D-LIF RGB-IR 双模态目标检测

无人机在夜间、逆光、强雾等低照度条件下执行任务时, 可见光图像的目标信息损失是不可逆的, 任何单模态增强手段在极端场景下均难以弥补。红外相机的热辐射特性恰好与可见光形成天然互补——夜间 IR 图像中人体、车辆等热源目标的对比度反而优于白天, 这使得 RGB-IR 双模态融合成为提升全天候检测可靠性的根本性方案。




图 3 M2D-LIF 架构图

本项目引入 ICCV 2025 提出的 M2D-LIF 框架, 直接针对多模态检测中长期存在的融合退化问题——即 RGB-IR 联合训练时各模态分支的单模态特征提取能力反而弱于独立训练, 导致融合后精度不升反降。M2D-LIF 通过两个核心模块协同解决这一问题: M2D 模块在联合训练中引入单模态蒸馏约束, 强制各分支保持充分的单模态表征能力; LIF 模块则根据图像局部区域的光照强度, 自适应地调节 RGB 与 IR 特征的融合比例——光照充足区域偏重色彩语义丰富的 RGB 特征, 低光区域则将权重倾向热辐射

射稳定的 IR 特征，无需人工设定固定融合系数。

在 DroneVehicle 数据集（含配对 RGB-IR 无人机航拍图像对，覆盖白天与夜间场景）上的验证结果表明，TianYing-MM 在 DroneVehicle 验证集上达到 $mAP@0.5 = 75.24\%$ (0.7524)，较 M2D-LIF HBBox 公开复现基准 (74.19%) 提升 +1.05pp，充分证明了多模态融合在全天候无人机检测场景下的显著价值，故作为引入多模态的范本。

TianYing-MM 较 M2D-LIF HBBox 公开复现基准提升 +1.05pp；在严格定位指标 $mAP@0.5:0.95$ 上 (0.5576) 超越 RGB 单专家模型 (0.5462) +1.14pp，进一步量化验证了跨模态注意力对齐对边界框回归精度的提升，各类别 AP 明细详见 5.1.3 节。

2.3 系统创新：从检测工具到智能感知平台

2.3.1 自适应切片推理：高分辨率大图中的小目标不再漏检

将 1920×1080 高分辨率图像整体缩放至标准推理尺寸时，原图中 8px 量级目标因缩放造成的信息损失是无法通过模型改进弥补的。本项目设计自适应切片推理策略，将原始图像按 20% 重叠率切割为多个 640×640 子图独立推理，子图结果映射回原始坐标系后执行跨切片非极大值合并，消除切片边界的重复检测，并可选融合一次全图低分辨率推理结果以保障大目标召回。TianYing-Det 单切片推理速度 115.5 FPS (640 px, FP32, RTX 5090)，达到赛题 25 FPS 要求的 4.6 倍；4 切片全图模式端到端约 28 FPS，仍满足实时性要求。TianYing-Det 在 VisDrone 验证集上取得 $mAP@0.5 = 63.55\%$

(0.6355)、 $mAP@0.5:0.95 = 41.12\%$ (0.4112) 的成果，为全部实验配置中的最优结果，相较同骨干直接高分辨率推理提升约 +4.30 个百分点，在 car、pedestrian、motor、bus 四个主要类别上，TianYing-Det $mAP@0.5 = 78.87\%$ ，满足赛题 $\geq 75\%$ 要求，充分证明了切片推理策略在高分辨率小目标密集场景下的核心价值。

2.3.2 天鹰 Agent：感知-决策-分析三层智能决策框架

传统检测系统固定模型、固定参数、对所有场景一视同仁，在场景突变、密度异常、极端光照等情况下会出现系统性失效，且其输出始终停留在“框”的层面，无法感知“发生了什么”。天鹰 Agent 框架将底层检测能力统一纳入三层闭环智能体架构，使系统具备持续感知场景状态、自主调整推理策略、主动识别异常事件并生成可解释报告的能力。

L1 感知层作为每帧必经的快速通路 ($<1ms$)，对每帧检测结果运行四类触发条件扫描：连续多帧摩托车目标出现、单帧目标密度超阈值、低置信度目标占比异常升高、周期性巡检到期。触发条件满足时以非阻塞方式将当前帧异步提交 MLLM 分析队列，主推理路径对上层逻辑完全透明，无任何附加延迟。

L2 决策层采用异步非阻塞架构，每 60 帧周期触发或由异常事件驱动，将当前帧与检测摘要送入 Qwen3-VL 进行深度场景分析，输出包含场景描述、事件研判与行动建议的可解释分析报告，异步推送至前端告警面板，同时写入数据库持久化存储，形成“规则快速响应 + 大模型深度解析”的协同机制。60 秒冷却期防止高频调用造成算力浪费，MLLM 服务不可用时自动降级兜底。

L3 分析层以检测结果的时序序列为输入，实现四类自主分析任务：周期场景巡检、低置信度异常诊断、人群/车辆密度异常告警，以及骑手头盔合规检测。每类任务均遵循“规则引擎快速初筛 + MLLM 语义确认”两阶段协同设计，每次分析输出含场景描述、事件推理、行动建议三个模块的可解释报告，通过 WebSocket 实时推送前端。整条主

推理路径的 Agent 附加开销低于 2ms, MLLM 分析全程异步执行, 对帧率无任何影响。

3 总体技术实现

3.1 技术路线总览

本项目以 YOLOv11-L 为检测骨干, 基于 PyTorch 框架构建完整训练与改进流水线, 依托 Ultralytics 生态进行模型配置与数据管道管理。算法层覆盖从数据到推理的六维创新; 工程部署层以 TensorRT FP16 完成端侧加速; 后端服务基于 FastAPI 提供推理接口; 天鹰 Agent 以异步协程调度 Qwen3-VL 进行场景语义分析; 前端通过 WebSocket 实时呈现可解释告警报告。主检测能力在 VisDrone2019-DET 上训练评估, 多模态感知能力在 DroneVehicle 数据集上独立验证。




图 4 天鹰智检系统技术架构图

3.2 整体模型架构

本项目模型体系由三个组件协同构成: 集成 P2 Head、CBAM、SFKR 重参数化卷积与 WIoU v3 的小目标检测模型 (管线 A) 覆盖白天通用场景; 以 M2D-LIF 为核心的 RGB-IR 双模态检测模型 (管线 B) 应对夜间与恶劣光照场景; 天鹰 Agent 三层触发分析框架在管线 A 实时检测基础上提供场景级语义理解能力, 形成检测-分析完整闭环。管线 B (M2D-LIF) 已完成算法研究与 DroneVehicle 验证, 作为全天候感知扩展能力预留, 尚未集成至当前运行时系统。

3.2.1 小目标检测模型架构 (管线 A)

管线 A 以 YOLOv11-L 为基础, 在标准三尺度检测结构上新增 P2 检测头, 形成 P2/P3/P4/P5 四尺度检测结构, 实现从 8px 超小目标到大尺寸目标的全覆盖。P2 分支在 FPN 上采样路径末端与骨干浅层特征 Concat 融合, 并接入 CBAM 注意力模块压制背景噪声; SFKR 重参数化卷积模块嵌入 P2 层特征提取路径, 训练期四路并行分支

捕获多频谱细粒度特征，推理时折叠为单路 7×7 DW+PW，等效感受野从 3×3 扩展至 7×7 ，延迟增加约 3 - 8%。训练阶段配合稀有类别感知重采样与 WIoU v3 损失函数，使难样本学习效率显著提升。在探索阶段，本项目尝试引入 TPRD 蒸馏策略对模型进行后训练微调，实验中在部分类别区分度上观察到局部提升，但在 VisDrone 密集小目标场景下整体增益有限，综合考量训练成本与收益后，最终部署版本以四组件基础架构为最优配置。

各模块逐步叠加的消融实验结果如下，每阶段均在 VisDrone 验证集上独立评估：

表 1 消融实验结果图

模型配置	核心组件	mAP@0.5	mAP@0.5:0.95	较基线提升
YOLOv11L 基线	—	0.4776	0.2903	—
+ P2 检测头	stride=8 超小目标特征层	0.496	0.3052	+1.84 pp
+ CBAM 注意力	通道 $\times$ 空间双注意力，置于 P2 层	0.5897	0.3751	+9.65 pp
P2 + CBAM + SFKR + WIoU v3	SFKR 重参数化卷积 + WIoU v3 回归损失	0.5925	0.3751	+11.49 pp

3.2.2 多模态检测模型架构（管线 B）

管线 B 以 M2D-LIF 框架为核心，设置独立的 RGB 与 IR 编码器分支，通过 M2D 单模态蒸馏约束在联合训练中同步维护各模态的单模态表征质量，再由 LIF 光照感知融合模块将双路特征按局部光照强度自适应加权融合后送入检测头。

3.3 应用程序

3.3.1 整体构架图

天鹰智检应用程序采用前后端分离的分层架构，纵向划分为表现层、服务层、推理层与数据层四个层次，横向支持桌面端、网页端与移动端三种接入形态，各层通过标准化接口解耦，保证系统的可扩展性与可维护性。

天鹰智检：系统总体架构




图 5 系统总体架构图

表现层负责用户交互与结果渲染，桌面端基于 Tauri v2 框架封装，具备本地推理能力；网页端通过浏览器直接访问，零安装门槛；移动端（React Native 原生应用）提供移动场景下的轻量接入。

服务层以 FastAPI 为核心框架提供 RESTful 接口与 WebSocket 实时推流，天鹰 Agent 调度器以异步协程方式驱动 L1/L2/L3 三层分析逻辑，与主推理路径完全解耦；用户鉴权基于 JWT Token，RBAC 权限体系管控不同角色的功能访问边界。

推理层内置双推理管线：管线 A 加载 YOLOv11-L 小目标检测模型（支持 PyTorch 与 TensorRT FP16 两种后端切换），并预置 M2D-LIF 双模态模型（管线 B）作为可选推理后端，管线 B（M2D-LIF）作为扩展接口预留，尚未纳入当前部署包。

数据层以 SQLite 作为嵌入式数据库存储检测历史、用户信息与告警记录，模型文件与导出数据持久化至本地文件系统，支持 JSON / CSV 两种格式的结构化导出。

3.3.2 运行流程

天鹰智检·检测数据流程图




图 6 检测数据流程图

完整的运行流程如下：

(1) 输入接入：用户通过前端界面选择检测输入源（本地摄像头、上传视频文件或后端 RTSP 流），前端将帧数据以 JPEG 格式压缩后，经 WebSocket 或 HTTP 接口上传至服务层。

(2) L1 感知：服务层接收帧后，天鹰 Agent L1 层在 <1ms 内对检测结果执行触发条件扫描（连续摩托车帧、密度超阈值、低置信度占比、周期到期），若触发则将帧异步入队待 MLLM 分析，主路径继续处理下一帧，无额外延迟。

(3) 目标推理：预处理后的帧送入推理管线 A 完成前向推理，输出原始预测框与置信度分布。切片推理机制按 20% 重叠率对输入帧切块后并行推理，各切片结果映射回原始坐标系后执行跨切片非极大值合并。

(4) L3 分析：推理结果实时流入 L3 分析层，规则引擎对当前帧执行四类告警条件检测（低置信度异常、密度超阈值、周期巡检、头盔合规）。触发条件的任务以非阻塞方式异步提交至 MLLM 分析队列，主路径继续处理下一帧，不引入任何等待开销。

(5) 结果推送：检测结果与统计数据通过 WebSocket 实时推送至前端，渲染检测框、置信度叠加与趋势图表；MLLM 分析完成后，告警卡片（含场景描述、事件分析、行动建议）异步推送至前端告警面板，同时写入数据库持久化存储。

(6) 数据归档：每次检测任务的完整记录（帧数、FPS、目标统计、告警事件）在任务结束后写入 SQLite 数据库，供历史检测模块查询与数据导出模块使用。

3.3.3 程序工具链

系统各层次所依赖的核心工具链如下：

算法训练与模型开发

本项目基于 PyTorch 深度学习框架与 Ultralytics YOLOv11 生态进行模型构建与

训练流水线管理，DINOv2-Large 特征提取通过 Hugging Face Transformers 接口调用，训练过程日志记录使用 TensorBoard 可视化监控。消融实验的模型权重管理与对比评估依托 Ultralytics 原生验证流水线完成。

推理加速

PyTorch 模型通过 Ultralytics 导出工具转换为 TensorRT FP16 引擎，在 NVIDIA GPU 上实现低延迟推理。OpenCV 与 Pillow 协同负责图像读取、预处理与视频流解码；自适应切片推理的坐标映射与跨切片 NMS 逻辑以纯 NumPy 实现，保证与推理框架的解耦。无人机端 RTMP/RTSP 推流通过 mediamtx 中继服务进行转发，确保多端画面接入的稳定性。

后端服务

后端服务基于 FastAPI 0.104+ 框架构建，以 Uvicorn 作为 ASGI 服务器支撑高并发异步请求；WebSocket 协议实现检测结果的实时双向推流；用户鉴权采用 JWT（Access/Refresh Token）结合 bcrypt 加密的安全方案；数据持久化使用 SQLite 嵌入式数据库配合 aiosqlite 驱动，通过 SQLAlchemy ORM 进行模型映射，数据结构校验由 Pydantic v2 完成；MLLM 调用通过 OpenAI SDK 对接 SiliconFlow 平台的 Qwen3-VL-32B-Thinking 模型，以异步协程方式集成至系统推理链路中。

桌面端与网页端

前端统一采用 React 18 + TypeScript 组件化架构，以 Vite 5 作为构建工具，React Router 6 管理 SPA 路由，Zustand 提供轻量全局状态管理，Axios 负责 API 通信并支持 Token 自动刷新。界面样式基于 Tailwind CSS 原子化方案构建，Framer Motion 实现页面与组件动画，ECharts 5 承担数据可视化渲染，Lucide React 提供矢量图标，高德地图 JS API 用于态势大屏的地理信息展示，MLLM 返回的 Markdown 格式分析报告通过 react-markdown 渲染呈现。桌面端在此基础上通过 Tauri v2 封装为跨平台原生应用，支持 Windows、macOS 与 Linux。

移动端

移动端基于 React Native 开发，面向 iOS 14.0 以上与 Android 8.0 以上原生设备发布，通过 HTTP REST API 与 WebSocket 与后端服务通信，实现实时检测画面接收、告警推送及 MLLM 分析调用等核心功能。

3.3.4 分级式信息管理系统

系统基于 RBAC（基于角色的访问控制）构建分级式信息管理体系，将用户划分为超级管理员、普通管理员与操作员三个权限层级，信息的生产、流转与查看均受所属角色约束，兼顾功能完整性与数据安全性。

超级管理员拥有平台全局管控权限，可访问态势大屏、性能报告、检测历史（全平台）、模型对比、MLLM 案例库与系统监控等所有后台模块，并具备用户账号创建、角色配置与权限变更的管理能力，同时可查看完整操作审计日志。

普通管理员可访问全部检测功能模块（实时检测、数据仪表盘、智能对话、多场景测试）与工具模块（检测历史、模型管理、数据导出），以及个人范围内的账号管理功能，但无法访问全平台用户数据与底层系统监控指标。

操作员的权限范围集中于核心检测功能：实时检测、个人历史记录查看与数据导出，

以及智能对话模块的使用，无法访问模型管理、系统设置与任何管理后台页面，保障平台核心配置数据的安全隔离。

在告警信息分级方面，系统将告警事件按紧急程度划分为三个等级：红色告警（高风险事件，如禁区入侵）需立即响应，系统自动推送通知至前端并记录至数据库；黄色告警（中等风险，如密度超阈值）触发 MLLM 深度分析并生成可解释报告；蓝色提示（低风险，如周期场景巡检报告）仅在报告面板静默展示，不触发强提醒。各等级告警均可在移动端告警中心一键标记已读，并支持按类型与时间范围筛选查阅。

4. 无人机视觉检测系统应用交互演示

本系统同时提供桌面端、网页端与移动端三种使用形式，三端功能模块高度一致，界面设计统一，支持用户在不同环境下灵活接入使用。其中桌面端与网页端功能基本一致，移动端在核心功能基础上针对移动场景进行了针对性设计与优化。

4.1 用户登录界面



图 7 登陆界面

系统登录界面设计简洁，三端均支持以下两种登录方式：

(1) 已有用户登录：从系统中选择已有账号，输入对应密码完成身份验证后进入系统主界面。

(2) 新用户注册：输入新账号与密码后，系统自动完成注册并同步写入用户信息。

4.2 核心功能栏展示

4.2.1 实时检测模块



图 8 实时检测模块主界面

用户登录后直接进入实时检测模块。页面顶部实时显示 STATUS, INFER, CONF, IOU, TARGETS, AVG CONF, FRAME 等运行状态指标，便于用户随时掌握系统性能。页面中央区域实时渲染当前帧的检测结果，并叠加对应目标的置信度数值，视觉呈现直观清晰。


页面右侧设有实时统计栏，从上至下依次展示当前帧检测结果与累计检测数量、类别分布饼状图、置信度分布柱状图及目标数量趋势折线图。

底部集成天鹰 Agent 智能监听模块，可对检测画面进行自主分析与异常预警，实现检测与分析的实时联动。



实时监控模块支持三种输入源模式，充分适应一线人员多样化的现场接入条件：


(1) 无人机模式：手机与桌面端连接至同一 Wi-Fi 后，接收桌面端已连接的无人机推流，查看 AI 标注画面。延迟最低，适合无人机航拍巡检场景下的实时目标检测与态势感知。



(2) 摄像头模式：调用本机摄像头进行实时采集，采用 3 路并发上传机制，不等待上一帧返回即可连续上传，并实时显示后端返回的带框标注图。该模式专为外勤巡检场景设计——一线人员无需携带额外设备，直接用手机摄像头即可完成现场目标检测，极大降低了硬件门槛，同时支持暂停与截图操作。

(3) 上传视频模式：从手机相册或文件管理器选择本地视频上传，上传完成后进行 AI 检测，支持 MP4、MOV 等常见格式，检测过程支持暂停/恢复，适合现场录制后回传分析的工作流。

页面顶部实时显示当前延迟 (ms)、帧率 (FPS) 与推理帧率，并以状态指示灯标注在线人数与运行状态 (ON/OFF)。底部操作栏提供暂停 / 继续、截图、AI 分析等快捷操作，关键功能以大按钮布局呈现，方便用户在户外强光或手套状态下单手操作。检测结果区域实时展示目标分类统计（如行人、汽车、货车等），系统状态区显示当前登录用户及视频来源信息。



头盔佩戴合规检测是本系统面向交通安全治理场景的专项功能，作为天鹰 Agent L3 分析层的内置任务之一，在实时检测流程中以零额外延迟的方式并行运行。

在检测逻辑层面，系统首先由主检测模型识别画面中的摩托车与骑手目标，随后对每个骑手检测框执行 RoIAlign 特征裁剪，提取头部区域子图，并通过轻量分类头判断是否佩戴头盔，输出"佩戴头盔 / 未佩戴头盔 / 置信度不足"三态结果。当连续多帧检测到骑手未佩戴头盔时，L1 感知层触发异步分析请求，将当前帧送入 MLLM 队列进行语义确认，生成包含目标位置、违规类型与处置建议的可解释告警报告，以黄色告警等级推送至前端告警面板，并持久化写入数据库。

MLLM 案例库中已收录头盔违规场景的典型分析案例（详见 4.5.4 节），管理员可通过"safety"标签快速检索相关 AI 研判报告，用于合规巡查存档与事后复盘。

4.2.2 数据仪表盘模块




图 9 数据仪表盘界面

数据仪表盘模块为用户提供多维度的数据汇总与可视化展示。

(1) **数据仪表盘统计信息展示：**在数据仪表盘页面上方，系统对当前检测情况进行了展示，信息包含累计检测数量、系统连续运行时长以及今日检测数量，用户可以根据这些数据，掌握当前系统运行基本的数据情况。

(2) **数据仪表盘近 7 日检测趋势展示：**在界面的中上部分，系统对近 7 日的检测情况进行了统计并展示，鼠标悬停至某日曲线节点可弹出当日详细数据。

(3) **数据仪表盘饼状图展示：**系统分析累计检测情况并利用饼状图展示各类类别的数量占比，用户通过观看饼状图可以掌握道路上各类车辆以及行人数量的变化趋势。

(4) **数据仪表盘柱状图展示：**系统分别针对晴天、雨天、雾天和夜间四种极端情况下的模型性能进行了测试，用户通过柱状统计图可以直观了模型在各类不同环境下的表现性能，对模型的鲁棒性有一个全面的了解。

4.2.3 智能对话模块



图 10 智能对话模块

智能对话模块将大语言模型能力与实时检测画面深度融合，支持用户对当前检测界面发起 AI 语义分析与智能问答。

用户可在页面顶部自由选择分析所用的多模态语言模型，灵活匹配不同分析需求。同时页面右上角提供一键截图功能。

4.2.4 多场景测试模块




图 11 多场景测试模块

多场景测试模块以视频流的形式，直观展示模型在晴天、雨天、雾天、夜间四种典型环境下的实际检测效果，全面展现模型的泛化能力与场景适应性。

用户既可逐一点击单个场景进行独立测试与细节观察，也可点击右上角的批量测试按钮同时启动四路视频流进行并行对比。

页面设有重置按钮，点击后所有视频将恢复至未播放的初始状态，方便重复测试。

4.3 工具栏展示

4.3.1 检测历史模块




图 12 检测历史模块

检测历史模块以结构化表格形式完整记录系统内所有历史检测任务，每条记录涵盖任务 ID、数据来源类型、目标数、检测帧数、运行 FPS、时长及执行时间等关键字段，信息详尽，便于回溯。模块顶部提供搜索框，支持按任务名称或 ID 快速定位；同时支持按日期范围、数据来源及运行状态进行多条件组合筛选，帮助用户精准检索目标记录。点击任务 ID 下拉窗口可以查看具体类别检测数量和源文件路径的详细信息。

此外，用户可对选中记录执行批量删除操作或单个记录的删除，并支持将历史记录整批导出。

考虑到移动端屏幕空间有限、用户操作习惯以滑动浏览为主，移动端检测历史模块在保留核心信息的前提下对展示形式进行了专项适配：每条历史记录以卡片形式呈现检测目标总数、运行帧率、时长及目标类别明细；点击展开单条记录可查看类别分布条形图，以色条长短直观呈现各类别目标数量的比例关系；顶部提供文件名筛选栏以便快速定位；支持两种导出格式；用户可上滑加载更多历史记录，底部提示已全部加载完毕时停止分页，交互方式更贴合移动端使用习惯。

4.3.2 数据导出模块




图 13 数据导出模块

数据导出模块以列表形式汇总所有历史检测任务，展示各任务的文件路径、检测日期、文件大小、帧数及 FPS 等基本信息。用户可勾选单个或多个任务，并选择 JSON 或 CSV 两种导出格式，其中 JSON 格式适用于二次开发与接口对接，CSV 格式便于在 Excel 等工具中进行数据分析。支持自定义导出路径及检测帧数范围的灵活配置。

4.4 系统栏展示

4.4.1 系统设置模块




图 14 系统设置模块-1

系统设置模块提供六大类配置项，覆盖检测行为、告警策略、界面偏好、截图管理、无人机接入及智能对话模型等核心参数，支持用户对系统进行全方位的个性化配置。

(1) 检测参数区：通过滑块直观调节置信度阈值（Confidence Threshold，建议范

围 0.25~0.50) 与 NMS IoU 阈值 (Non-Maximum Suppression, 建议范围 0.45~0.65), 精细控制检测结果的输出标准, 平衡漏检与误检之间的取舍。

(2) 告警规则区: 支持独立开关三类告警策略: 入侵检测告警 (检测到人员进入监控区域时触发)、密度告警 (目标数量超过设定阈值时触发, 阈值可通过滑块在 10~200 之间调节)、低置信度告警 (平均置信度低于 30% 时触发), 用户可根据实际监控场景灵活配置。




图 15 系统设置模块-2

(3) 界面偏好区: 提供界面语言切换 (中文 / English)、FPS 实时显示及 GPU 状态显示等选项, 满足不同用户的使用习惯。

(4) 截图设置区: 支持自定义截图文件的本地保存目录。桌面端填写绝对路径, 浏览器端留空时默认使用浏览器下载目录。




图 16 系统设置模块-3

(5) 无人机推流区: 管理 RTMP 推流接入配置, 包括推流服务器 IP 设置、推流密钥的生成与重置、RTMP 推流地址的复制, 并提供三步操作引导, 帮助用户快速完成

无人机画面的实时接入。




图 17 系统设置模块-4

(6) 后端连接与智能对话 (MLLM) 区：支持配置后端 API 服务器地址并提供连接测试功能；智能对话模块可设置推理模式（自动 / 本地 / API / Mock）、API Key、Base URL 及多模态大语言模型名称，并提供快速切换模型的快捷入口与连接状态验证。

页面底部提供"恢复默认"与"保存所有设置"两项全局操作，确保配置变更可统一提交或一键还原。

移动端的目标用户群体以外勤操作人员为主，其日常需求侧重于快速接入、状态确认与告警配置，而非对系统参数进行深度调整。因此移动端将设置功能以更轻量、更聚焦的"我的"模块形式呈现，去除了桌面端中面向专业用户的复杂参数项，保留与移动场景最密切相关的核心配置：

①账号信息区：显示当前登录用户的头像、用户名及账号角色，以绿色圆点标注账号在线状态；

②网络连接区：展示当前配置的服务器地址，支持编辑修改及一键测试连接；

③告警设置区：提供禁区入侵告警、密度异常告警、低置信度告警三类告警开关，所有设置即时保存并同步至服务端；

④网络诊断区：面向运维人员提供底层网络连通性排查工具，自动检测 Storage、URL、Token、网络连通性等关键项目状态并输出诊断结果；

⑤系统信息区：展示当前 App 的版本号、运行框架及开发团队等基础信息；

⑥页面底部提供"退出登录"按钮，系统清除本地登录凭据后返回登录界面。

4.4.2 用户管理模块




图 18 用户管理模块

用户管理模块基于 RBAC 权限体系构建，以列表形式清晰展示系统内全部注册用户的信息，并以状态标签实时标注账号活跃状态。

管理员可在此直接添加新用户、修改用户信息、重置账号密码、配置用户角色权限或删除指定账号。

页面同时提供“操作日志”标签页，以表格形式完整记录操作者、动作类型（登录 / 登出等）、目标用户、详情及执行时间，便于管理人员对系统访问行为进行追溯与审计，保障权限管理的安全性与可追溯性。

页面右上角提供“添加用户”功能，点击后弹出新用户创建表单，需填写用户名（3~64 位字母数字）、初始密码（至少 6 位），并从操作员、管理员、超级管理员三种角色权限中选择一项，确认后即可完成账户创建。

移动端的管理人员往往需要在巡查途中临时处理账号事务，如为新到岗人员快速开通权限等，但移动设备上进行复杂的表单操作体验较差。因此移动端将用户管理以轻量化形式集成于“我的”模块的账号管理区，以用户列表直观呈现各账号的用户名、角色标识与在线状态，管理员可通过右上角“+ 新增”按钮快速完成新用户账号的创建，满足移动场景下的即时管理需求，同时避免引入过多操作层级增加使用负担。

4.4.3 我的账号模块




图 19 我的账号模块

我的账号模块集中展示当前登录用户的个人账号详情，包括用户名、账号角色、账号注册时间及上次登录时间等基础信息，帮助用户随时核对自身账号状态。

模块内置密码修改功能，填写新密码时会显示密码安全程度等级，用户依次填写当前密码、新密码及确认密码后，点击保存按钮即可完成账号密码的更新，全程在客户端本地完成校验，保障账号安全。

4.5 管理员报告后台

网页端的核心用户群体为城市交管部门、园区安防平台等机构的管理人员，其工作重心在于对系统整体运行状态的宏观把控、对算法性能的周期性评估以及对多用户任务数据的统一治理，而非驻守前端进行实时检测操作。依托浏览器天然的跨平台访问能力，网页端专门构建了管理员报告后台，将全局态势感知、模型性能量化评估、平台级检测历史审查、MLLM 典型案例沉淀及服务器资源监控等管理职能集中于此，桌面端和移动端暂无此功能模块。

4.5.1 态势大屏




图 20 态势大屏

态势大屏是面向管理员的全局运营监控中心，以中国地图为底图，通过热力图层直观呈现各省市地区检测任务的地理分布与密度情况，支持任务密度分级着色，管理员可快速识别重点监控区域。

左侧面板实时显示系统检测总量、当日告警数量及最新告警事件列表；右侧面板展示当前激活模型的推理性能指标与系统整体健康度；底部汇总高频检测任务 TOP5 城市排名，以及系统服务可用率、API 响应率等关键运维指标，辅助管理员全面掌控平台全局运营态势。

4.5.2 性能报告

28

性能报告模块为管理员提供当前模型的全面量化评估，面向需要对算法质量进行定期审核与汇报的技术主管与项目负责人。

顶部指标卡片分别展示 VisDrone 与 DroneVehicle 两大数据集上的核心精度结果：当前版本在 VisDrone 上达到 $mAP@0.5$ 59.25%、 $mAP@0.5:0.95$ 37.51%，相较基线提升 +11.49 pp；DroneVehicle RGB 专家模型则取得 $mAP@0.5$ 77.69%、 $mAP@0.5:0.95$ 54.62%，较 M2D-LIF HBBBox 基准提升 +3.50 pp。


中部通过消融实验对比表呈现 P2-C 检测解耦头、P2-C 传统检测头、SFAN 优化等关键模块对精度的逐步贡献，并配合 PR 曲线与 F1-Confidence 曲线直观展示模型的整体检测质量。

逐类别 AP50 条形图细化呈现 pedestrian、bicycle、car、van、truck、bus 等各目标类别的检测性能差异，归一化混淆矩阵则进一步揭示类间误检规律，例如 freight-car 与 truck 之间存在一定混淆。

推理速度方面，报告横向对比了 TianYing-Full (1280 px, 44.2 FPS)、TianYing-Det (640 px, 115.5 FPS) 以及轻量化部署版本 TianYingLite-MM (模型体积 37 MB，压缩率约 54%，可达 128.6 FPS) 等多个推理配置，并记录了切片专精训练策略下 TianYing-Det 在 VisDrone 验证集上取得 $mAP@0.5$ 63.55% 的实验结论。

将上述模型量化评估报告集中于网页端，是考虑到此类数据分析工作更多发生在事后复盘而非实时监控阶段，管理人员习惯于在办公室通过浏览器访问报告，而非在专用监控工作站前完成分析工作。

4.5.3 检测历史



任务 ID	来源	状态	检测目标	FPS	时长	耗时
task_20260412_141755	video	default	2.2K	7.4	10s	04/12 14:17
task_20260412_141626	video	default	8.1K	18.8	20s	04/12 14:16
task_20260412_141341	video	default	1.4K	14.3	5s	04/12 14:13
task_20260412_134539	video	default	418	3.2	7s	04/12 13:45
task_20260411_232933	video	default	296	9.3	1s	04/11 23:29
task_20260411_231383	video	default	5.2K	13.1	18s	04/11 23:13
task_20260411_195827	video	default	18.4K	17.9	27s	04/11 19:58
task_20260411_194547	video	default	1.2K	8.8	2177s	04/11 19:45
task_20260411_185819	video	default	2.6K	8.8	1382s	04/11 18:58
task_20260411_185805	video	default	2.1K	13.3	8s	04/11 18:58
task_20260411_173525	video	default	845	8.5	93s	04/11 17:35
task_20260411_161255	video	default	1.0K	19.5	3s	04/11 16:12
task_20260411_161834	video	auto	0	0.0	0s	04/11 16:18
task_20260408_148741	video	default	18.4K	21.6	22s	04/08 14:07
task_20260408_148735	video	default	2.4K	21.4	6s	04/08 14:07

图 22 检测历史界面

管理员检测历史模块汇总展示全平台所有用户提交的历史检测任务记录，每条记录包含任务 ID、数据来源类型、运行状态、关联模型、检测帧数、运行 FPS、任务时长及执行时间戳等完整字段信息，数据覆盖全面。

模块支持按任务名称、ID、日期范围及运行状态进行多条件组合检索与筛选，便于管理员快速定位特定任务记录。

所有任务记录均可进行批量操作，管理员可对全平台检测任务进行统一监督、合规审计与数据治理。

4.5.4 MLLM 案例库




图 23 MLLM 案例库

MLLM 案例库为多模态大语言模型的实际应用效果提供典型场景的集中展示与沉淀，收录了交通路口、消防通道、校园操场、头盔佩戴等多类真实检测场景的代表性案例。每条案例配有高清场景图片与 AI 生成的详细语义分析描述，涵盖目标数量统计、关键发现和建议等内容。模块顶部提供场景标签筛选栏，支持按 traffic、parking、campus、safety 等标签快速过滤浏览，帮助用户直观了解系统在不同场景下的 AI 分析能力边界。




图 24 MLLM 案例库头盔佩戴情况分析

4.5.6 系统监控




图 25 系统监控

系统监控模块为管理员提供对服务器底层资源状态的实时感知能力。

页面顶部以动态折线曲线实时展示 CPU 与 GPU 的使用率变化趋势，辅助判断计算资源是否存在过载风险；中部分别以进度环与进度条形式直观呈现内存使用量及磁盘各分区的容量占用情况。

右侧面板实时显示网络上下行速率及当前系统进程 PID 信息，便于快速定位资源消耗来源。

页面底部的异常事件日志区域实时滚动记录系统告警事件，帮助运维人员及时发现并响应异常，保障系统稳定安全运行。

4.6 告警中心模块

移动端用户多为需要随时响应异常的一线巡检或外勤人员，无法像桌面端用户那样持续驻守工作站监控屏幕，因此对告警信息的即时推送与快速研判有着更强烈的需求。为此，移动端专门设计了独立的告警中心模块，集中展示系统生成的所有告警事件，顶部标注未读告警总数并提供"全部已读"一键标记功能。

页面支持按告警等级分类查询，包含全部、高危、中危、低危四种筛选方案。每条告警记录包含告警类型标签、警告等级标签、未读/已读状态标签、告警详情描述及触发时间。

用户点击单条告警可查看详细信息，包括触发该告警的检测帧截图与目标坐标信息，便于快速研判现场态势。同时，移动端主页底部的"最近告警"区域实时滚动展示最新告警事件摘要，用户无需切换至告警页面即可第一时间感知异常。

5.性能测试

5.1 模型算法性能

本系统模型性能评估采用统一的协议与工具链,以确保各实验结果具备横向可比性。VisDrone 任务使用官方 val 集 (548 张完整原图, 1280 px), DroneVehicle 任务使用 val 集 (1469 张, 960 px), 均采用水平框 (HBBBox) 评估协议, 通过 Ultralytics YOLO11 内置 model.val() 计算 mAP。推理速度测试在 NVIDIA GeForce RTX 5090 上进行, PyTorch FP32 精度, batch=1, GPU 预热 50 次后计时 200 次取均值, 排除数据预处理时间干扰。

项目	详情
VisDrone 评估集	VisDrone2019-DET val, 548 张完整原图, 分辨率 1280 px
DroneVehicle 评估集	DroneVehicle val, 1469 张, HBBBox 协议, 分辨率 960 px
评估工具	Ultralytics YOLO11 内置 model.val (), FP32 精度
速度测试环境	NVIDIA GeForce RTX 5090, PyTorch FP32, batch=1, GPU 预热 50 次后计时 200 次取均值
核心指标	mAP@0.5 (主要) / mAP@0.5:0.95 (严格) / FPS (实时性)

5.1.2 VisDrone 消融实验链

针对无人机航拍中小目标密集、背景复杂的核心挑战, 本系统以 YOLOv11L-640px 为基线, 逐步引入各组件验证独立贡献。P2 检测头在 640px 输入下贡献 +1.84 pp; 升至 1280px 高分辨率后, P2 层与高分辨率特征协同放大, 带来最大单步跃升 +8.44pp; 进一步加入 WIoU v3 动态聚焦损失 (+0.54 pp)、CBAM 通道与空间双重注意力 (+0.39 pp) 和 SFKR 自研重参数化卷积 (+0.28pp), TianYing-Full 较基线累计提升 +11.49 pp (+24.1%), 并将收敛提前至第 10 个 epoch。在此基础上, 切片专精训练策略 (TianYing-Det) 进一步提升 +4.30 pp, 最终 mAP@0.5 达 63.55%, 主要四类目标达 78.87%, 满足赛题 $\geq 75\%$ 要求。

模型配置	核心组件	mAP@0.5	mAP@0.5:0.95	较基线 Δ
YOLOv11L 基线	—	0.4776	0.2903	—
+ P2 检测头	stride=8 超小目标特征层	0.496	0.3052	+1.84 pp
+ CBAM 注意力	通道 $\times$ 空间双注意力, 置于 P2 层	0.5897	0.3751	+9.65 pp
P2 + CBAM + SFKR + WIoU v3	SFKR 重参数化卷积 + WIoU v3 回归损失	0.5925	0.3751	+11.49 pp

从逐类别精度分解来看, 最优模型 EXP-05 在高频核心类别上表现突出: car AP 突破 90%, pedestrian、motor、van 等密集小目标类别相较基线均有 4–5 pp 的稳定提升。awning-tricycle 作为训练样本极度稀少的稀有类, AP 仅 0.26, 是当前模型的主要提升

空间。

类别	YOLOv11L 基线	EXP-05 最优	Δ
car	0.8925	0.9057	+1.32 pp
pedestrian	0.6866	0.724	+3.74 pp
motor	0.6436	0.693	+4.94 pp
van	0.5585	0.609	+5.05 pp
bus	0.7104	0.7239	+1.35 pp
mAP@0.5 (全 10 类)	0.4776	0.5925	+11.90 pp

5.1.3 DroneVehicle 多模态融合

单纯追求白天精度的 RGB 单专家模型固然能达到更高的 mAP 数字，但无法感知红外通道，在夜间与复杂光照条件下将完全失效。本系统采用 YOLO11L 双流架构结合 CWD 知识蒸馏与跨模态注意力（CrossAttention），构建了兼顾精度与全天候鲁棒性的多模态融合方案。与 M2D-LIF 论文 HBBox 复现基准相比，本系统双模态大模型提升 +1.05 pp，同时获得了 RGB 单专家模型所不具备的红外感知能力，满足赛题“不同时间段（日、夜）鲁棒检测”要求。

方法	模态	mAP@0.5	mAP@0.5:0.95	备注
M2D-LIF (HBBox 复现, 对比基准)	RGB+IR	0.7419	0.5682	横向对比锚点
DV_Expert_RGB (RGB 单专家)	RGB	0.7769	0.5462	精度上限 (无夜间能力)
DV_Multimodal_LIF v3 (最优)	RGB+IR	0.7524	0.5576	超基准+1.05 pp, 全天候

在逐类别精度上，主要车辆类别表现优异：car 与 bus 的 AP@0.5 均超过 95%，truck 超过 71%，整体 mAP 全面达到赛题 $\geq 75\%$ 要求。freight-car 作为遮挡严重的稀有小目标类别，AP 仅 0.54，是后续重点优化方向。

类别	AP@0.5	AP@0.5:0.95
car	0.9476	0.68
bus	0.9533	0.71
truck	0.7112	0.52
freight-car	0.5422	0.39
van	0.6077	0.45
mAP@0.5	0.7524	0.5576

5.1.4 TianYingLite 轻量化边缘模型

边缘部署场景对模型体积与推理速度有严苛约束，标准大模型（113 MB）难以直接上车。TianYingLite 以 Gold-YOLO GD 颈部替换标准 PAN-FPN，通过信息注入机制（GDInject）在大幅削减参数量的同时维持多尺度特征传递，并以 TianYing-Full / TianYing-RGB 为教师模型进行知识蒸馏，使轻量模型继承大模型的特征表示能力。最终模型压缩至 37 MB，并完成 ONNX 格式导出与 CPU 推理验证，可直接通过 trtexec 转换为 TensorRT 格式部署至边缘设备。

模型	数据集	mAP@0.5	mAP@0.5:0.95	模型大小	FPS
YOLOv11L 大模型 (EXP-03b)	VisDrone	0.5925	0.3751	113 MB	—
TianYingLite (轻量版, 640 px)	VisDrone	0.3694	0.2197	37 MB	116.3
DV_Multimodal_LIF v3 (大模型)	DroneVehicle	0.7524	0.5576	80 MB	55.1
TianYingLite-DV (轻量版, 960 px)	DroneVehicle	0.704	0.4803	37 MB	128.6

轻量化的核心代价在 VisDrone 任务上体现得较为明显 (mAP 下降约 22 pp), 但 DroneVehicle 任务上的精度保留则相当出色。以下逐类别数据表明, TianYingLite-DV 以约 46% 的模型体积, 在主要类别 car / bus 上仅损失 2 - 4 pp, AP@0.5 均保持在 90% 以上, 完整实现了轻量化目标。

类别	标注占比	YOLOv11L 基线	EXP-03b	EXP-05 (最优)	EXP-05vs 基线
car	高频	0.8925	0.8996	0.9057	+1.32 pp
pedestrian	高频	0.6866	0.7000	0.7240	+3.74 pp
motor	高频	0.6436	0.6817	0.6930	+4.94 pp
van	高频	0.5585	0.5954	0.6090	+5.05 pp
bus	低频	0.7104	0.7017	0.7239	+1.35 pp
people	中频	0.5058	0.5542	0.5790	+7.32 pp
truck	中频	0.4968	0.5129	0.5505	+5.37 pp
tricycle	低频	0.4252	0.4688	0.4687	+4.35 pp
bicycle	低频	0.3386	0.3885	0.4120	+7.34 pp
awning-tricycle	稀有	0.2318	0.2508	0.2586	+2.68 pp
mAP@0.5	—	0.4776	0.5925	0.5925	+11.90 pp
mAP@0.5:0.95	—	0.2903	0.3751	0.3751	+8.48 pp

5.1.5 推理速度汇总

本系统各模型的推理速度均经过严格计时验证。除定位为离线高精度模式的 CFAP (粗细协作推理管线, TianYing-Full 全图粗检测+ TianYing-Det 局部切片精检测, 经 Supplement NMS 融合) 管线外, 其余所有模型均大幅超越 25 FPS 实时推理要求, 其中轻量化模型 TianYingLite 系列在 640/960 px 分辨率下更达到 116 - 128 FPS 的高吞吐表现, 具备充足的算力余量用于多任务并发或更高分辨率推理。

模型	数据集	分辨率	延迟	FPS	是否满足 25FPS
EXP-05 (VisDrone 最优)	VisDrone	1280 px	22.64 ms	44.2	✓
SLICED_CBAM_D (切片专精)	VisDrone 切片	640 px	8.66 ms	115.5	✓
DV_Multimodal_LIF v3	DroneVehicle	960 px	18.1 ms	55.1	✓
TianYingLite (VisDrone)	VisDrone	640 px	8.6 ms	116.3	✓
TianYingLite-DV	DroneVehicle	960 px	7.8 ms	128.6	✓
CFAP 管线 (离线高精度) ¹	VisDrone	1280+640 px	~250 ms	~4.0	⚠ 离线模式

5.2 系统接口性能

系统接口性能测试覆盖 6 条核心 API，包含认证、检索、推理、报告等各类型端点。测试采用 pytest+httpx 框架，每条接口执行 3 次请求（检测接口 2 次）取均值，与预设响应阈值对比。测试环境为 Windows 11 本地开发机，后端服务运行于 localhost:8000。

用例 ID	接口	响应阈值	实测均值	结果
PT-01	POST /api/auth/login	500 ms	~205 ms	✓
PT-02	GET /api/dashboard/stats	800 ms	~16 ms	✓
PT-03	GET /api/tasks	800 ms	~7 ms	✓
PT-04	GET /api/report	1000 ms	~14 ms	✓
PT-05	GET /api/mlm/cases	500 ms	~13 ms	✓
PT-06	POST /api/detect (含推理)	5000 ms	~149 ms	✓

6/6 用例全部通过 (100%)。数据检索类接口 (dashboard、tasks、report) 响应均在 20 ms 以内，体现了后端缓存与数据库查询的高效性。含完整模型推理的检测接口实测约 149 ms，仅为 5000 ms 阈值的 3%，系统具备充足的性能余量以支持多路并发接入与未来功能扩展。

6. 开发环境与技术

操作系统：Windows 11

开发语言：Python 3.10 (后端) / TypeScript (前端)

深度学习框架：PyTorch2.x (CUDA 12.x)

目标检测生态：UltralyticsYOLOv11

推理加速：NVIDIA TensorRT10.x (FP16)

¹ CFAP 管线通过“全局粗检测 + 局部精检测”双流级联将 mAP 在官方评估体系下再提升 +0.62 pp，代价是单图延迟约 250 ms，定位为对帧率无约束的离线回溯分析场景，不参与实时性评估。

7.应用环境

本系统在设计阶段充分考虑了多样化的实际部署场景，针对服务器端部署、边缘端部署与客户端接入三种典型形态分别给出配置建议。

服务器端部署环境（推荐配置）

系统后端推理服务与调度框架建议部署于配备独立 NVIDIA GPU 的服务器或工作站。推荐使用显存 8GB 及以上的 NVIDIA RTX 30/40/50 系列 GPU 或更大算力的数据中心使用的 GPU（如 A100、L40S）；操作系统建议 Ubuntu 22.04 LTS，安装 CUDA 12.x 与 TensorRT 10.x 完成推理加速配置；内存建议 32GB 以上，本地存储建议 500GB 以上用于历史检测数据归档。该配置可支持多切片推理模式下 $\geq 25\text{FPS}$ 的稳定实时推理，并同时承载多路 WebSocket 连接。

客户端运行环境

桌面端基于 Tauri v2 构建，支持 Windows 10/11（64 位）与 macOS 12.0 以上，最低配置建议 Intel Core i5 第八代及以上处理器、16GB 内存；独立显卡非必须，CPU 推理模式可用，但帧率受限。

网页端基于 React + TypeScript + TailwindCSS 构建，支持 Chrome 100+、Edge 100+、Firefox 95+ 等主流现代浏览器，无需安装任何插件，通过局域网或公网访问后端服务即可使用全部功能，界面针对 1920×1080 桌面分辨率优化，采用深色主题管理后台风格。

移动端基于 React Native 构建，支持 iOS 14.0 以上与 Android 8.0 以上原生设备，无需微信等第三方平台，可直接安装 APK 或通过 App Store 分发。网络环境建议 4G 及以上或 Wi-Fi，以保障实时画面推流与 WebSocket 连接的稳定性。

网络环境要求

后端服务与各端客户端之间通过 HTTP（REST API）与 WebSocket 双通道通信，建议局域网内部署以获得最佳延迟体验（端到端通信延迟 $< 10\text{ms}$ ）；公网部署需确保服务器端口（默认 8000）已开放，移动端用户需在设置界面填写正确的服务器公网 IP 地址。

8.项目应用对象

8.1 桌面端应用对象

桌面端数据处理能力强，功能模块最为完整，无需依赖网络即可独立运行，适合部署于具有固定工作站或专用监控设备的应用场所。桌面端支持实时检测画面渲染、多路视频流输入（本地文件、USB 摄像头、RTSP 流）、本地模型推理与结构化数据导出，并集成了 MLLM 智能对话窗口，可对当前帧内容进行自然语言分析，尤其适用于数据量大、实时性要求高、对系统稳定性与本地化部署有严格要求的专业场景，如实际交通监控站、安防指挥中心等。

8.2 网页端应用对象

网页端适用于管理人员或远程用户的日常使用需求。相比桌面端，网页端更轻量、访问方式更灵活，无需安装任何客户端，支持通过浏览器随时随地查看系统全局状态与历史任务记录。网页端系统以“战后复盘”为核心定位，提供交互式算法性能报告（P-R 曲

线、各类别 AP、混淆矩阵、消融实验对比)、检测历史查询与筛选及数据集可视化分析等功能,充分发挥其跨平台、易部署、免维护的优势,适合城市交通管理部门、园区安防管理平台等多用户协同监管场景。

8.3 移动端应用对象

移动端基于 React Native 开发,使用门槛低、部署成本小,适用于需要随时随地掌握检测动态的一线人员或外勤管理人员。移动端支持实时接收检测画面推流并叠加展示检测框,可在手机上直观查看目标识别结果;同时支持禁区入侵、密度异常等告警推送与告警历史查阅,并集成 MLLM 分析入口,支持对检测画面进行语音或文字问答。移动端凭借其便携性与即时响应能力,尤其适合无法固定在工作站前的巡检人员、现场督导或应急响应人员,是桌面端与网页端在移动场景下的重要补充,三端协同形成完整的多终端智能检测生态。

9. 项目总结

本项目以 VisDrone 无人机航拍目标检测为核心任务,系统性地构建了覆盖数据层、架构层、训练层、知识层、多模态层、推理层与智能决策层的七维算法创新体系,最终形成天鹰智检完整技术方案。

在检测性能层面,通过稀有类别感知重采样、P2 超高分辨率检测头与 CBAM 注意力增强、WIoU v3 损失函数与 SFKR 重参数化卷积的逐层叠加,主模型在 VisDrone 验证集上实现了 $mAP@0.5$ 从基线的持续提升;进一步引入自适应切片推理策略后,最优配置 (TianYing-Det) 取得 $mAP@0.5 = 63.55\%$ 、 $mAP@0.5:0.95 = 41.12\%$,在 RTX 5090 上以切片模式实现 115.5 FPS 的实时推理速度,同时达成精度与实时性的双重目标。在多模态感知层面,引入 M2D-LIF 框架构建 TianYing-MM,于 DroneVehicle 数据集上实现 $mAP@0.5 = 75.24\%$,相比 M2D-LIF HBBBox 公开复现基准提升 +1.05 pp,填补了夜间与恶劣天气场景下的感知盲区。

在系统架构层面,天鹰 Agent 感知-决策-分析三层框架将底层检测能力与场景级语义理解统一纳入闭环智能体体系,实现了从"被动输出检测框"到"主动感知场景异常、生成可解释报告"的范式跃迁。整个主推理路径的 Agent 附加开销低于 2ms,MLLM 分析全程异步执行,对实时帧率无任何影响,系统级架构的工程化完成度达到可部署标准。

在工程实现层面,系统以桌面端、网页端与移动端三端并行的形式完成交付,覆盖专业监控工作站、远程运维浏览器访问与现场巡检移动场景,三端数据互通、功能高度一致,形成完整的多终端智能检测生态。

在项目开发历程中,团队经历了从技术选型到算法调优、从模块开发到系统集成的完整工程实践。消融实验的每一次迭代不仅是精度数字的变化,更是对目标检测方法论深层认知的积累;切片推理策略从构想到实现、Agent 框架从纸上设计到代码跑通,每一个阶段的突破背后都是无数次调试与重构的沉淀。

团队在协作过程中深刻体会到,算法创新与工程落地之间存在巨大的鸿沟——一个在论文中有效的方法,往往需要大量工程适配才能在实际系统中稳定运行;而一个高度完善的工程系统,也需要严谨的实验设计来支撑其核心性能指标。这种"研究思维"与"工程思维"的融合,是本项目留给团队最宝贵的收获。

感谢指导老师的全程悉心指导,感谢组委会老师的耐心支持,以及企业出题方在赛

题解读方面提供的帮助。天鹰智检从一个构想到完整系统的落地，离不开每一位参与者的付出与坚持。

参考文献

- [1] Du D, Zhu P, Wen L, et al. VisDrone-DET2019: The vision meets drone object detection in image challenge results[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. 2019.
- [2] Jocher G, Qiu J. Ultralytics YOLO11[EB/OL]. (2024).
- [3] Oquab M, Darcet T, Moutakanni T, et al. DINOv2: Learning robust visual features without supervision[J]. Transactions on Machine Learning Research, 2024.
- [4] Tong Z, Chen Y, Xu Z, et al. Wise-IoU: Bounding box regression loss with dynamic focusing mechanism[J]. arXiv preprint arXiv:2301.10051, 2023.
- [5] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 3–19.
- [6] Sun Y, Zhu P, et al. M2D-LIF: Multi-modal detection with light-aware interactive fusion for drone-based RGB-IR object detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2025.
- [7] Wu J, Cao J, Song L, et al. DroneVehicle: Bringing semantics to drone-based vehicle detection[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023.
- [8] Zhu P, Wen L, Du D, et al. Detection and tracking meet drones challenge[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(11): 7819–7836.
- [9] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2117–2125.
- [10] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLO[EB/OL]. (2023). <https://github.com/ultralytics/ultralytics>.